

卡尔曼滤波

Introduction

卡尔曼滤波器 (Kalman filter) 就是线性动态系统 (LDS, Linear dynamic system); 在控制领域中的卡尔曼滤波器, 可以参考这篇文章:

<https://www.bzarg.com/p/how-a-kalman-filter-works-in-pictures/>

在 neuroscience 领域, 卡尔曼滤波器用于神经信号的解码, 尤其是脑机接口中, 应用广泛; 但是在使用上、理解上和在控制领域可能有一点区别;

这里介绍在 neuroscience 领域中如何理解卡尔曼滤波器用于神经信号的解码。

算法讲解

以假肢的运动控制为例, 利用多电极阵列采集运动皮层的神经信号, 记为 $Y \in \mathcal{R}^{M \times K}$, 其中 M 表示电极通道的数目, K 表示时间, 用 $X \in \mathcal{R}^{N \times K}$, N 表示假肢的运动参数, 也就是控制假肢运动的信号;

因为是线性时不变系统, 所以有如下关系:

$$\mathbf{x}_k = \mathbf{A} \mathbf{x}_{k-1} + \mathbf{w}_k, \mathbf{x}_1 \sim \mathcal{N}(\omega, \Omega)$$

$$\mathbf{y}_k = \mathbf{H} \mathbf{x}_k + \mathbf{q}_k$$

其中: $\mathbf{w}_k \sim \mathcal{N}(0, \mathbf{W})$, $\mathbf{q}_k \sim \mathcal{N}(0, \mathbf{Q})$; $\mathbf{A} \in \mathcal{R}^{N \times N}$ 是状态矩阵 (state matrix), $\mathbf{H} \in \mathcal{R}^{M \times N}$ 是观测矩阵 (observation matrix)。

在控制系统中, 我们其实是清楚具体的动态关系的, 也就是 $\mathbf{A}, \mathbf{H}, \mathbf{W}, \mathbf{Q}$ 这些参数是已知的, 在实际的控制过程中, 每次都是根据估计得到的上一时刻的 $\hat{\mathbf{x}}_{k-1}$, 当前时刻的 \mathbf{y}_k 估计得到当前时刻的 $\hat{\mathbf{x}}_k$,

在神经信号解码的过程中, 其实是有一个训练过程的, 也就是先采集训练数据 (包括假肢的运动状态 \mathbf{X} 和神经信号 \mathbf{Y}), 然后根据这些训练用的数据先计算出固定的 $\mathbf{A}, \mathbf{H}, \mathbf{W}, \mathbf{Q}$, 计算方法如下:

$$\mathbf{A} = \underset{\mathbf{A}}{\operatorname{argmin}} \sum_{k=2}^K \|\mathbf{x}_k - \mathbf{A} \mathbf{x}_{k-1}\|^2$$

$$\mathbf{H} = \underset{\mathbf{H}}{\operatorname{argmin}} \sum_{k=1}^K \|\mathbf{y}_k - \mathbf{H} \mathbf{x}_k\|^2$$

可以利用最小二乘法进行求解, 得到:

$$\mathbf{A} = \mathbf{X}_2 \mathbf{X}_1^T (\mathbf{X}_1 \mathbf{X}_1^T)^{-1}, \text{ 其中 } \mathbf{X}_1 = \mathbf{X}_{:,1:K-1}, \mathbf{X}_2 = \mathbf{X}_{:,2:K}$$

$$\mathbf{H} = \mathbf{Y} \mathbf{X}^T (\mathbf{X} \mathbf{X}^T)^{-1}$$

有了 \mathbf{A} , \mathbf{H} 之后，就可以比较容易地获得：

$$\mathbf{W} = \frac{1}{K-1} (\mathbf{X}_2 - \mathbf{A} \mathbf{X}_1) (\mathbf{X}_2 - \mathbf{A} \mathbf{X}_1)^T$$

$$\mathbf{Q} = \frac{1}{K} (\mathbf{M} - \mathbf{H} \mathbf{X}) (\mathbf{M} - \mathbf{H} \mathbf{X})^T$$

至此，整个模型已经建立起来了，在实际的解码过程中，需要对当前的状态/控制信号 \mathbf{x}_k 进行解码。

已知有：

$$\mathbf{x}_k | \mathbf{x}_{k-1} \sim \mathcal{N}(\mathbf{A} \mathbf{x}_{k-1}, \mathbf{W})$$

$$\mathbf{y}_k | \mathbf{x}_k \sim \mathcal{N}(\mathbf{H} \mathbf{x}_k, \mathbf{Q})$$

在 $k-1$ 时刻最佳估计为 $\hat{\mathbf{x}}_{k-1}$ ，分布的协方差为 \mathbf{W}_{k-1}

One Step estimation

于是在经过一步估计之后， k 时刻的状态理论上应该是通过上一个时刻状态变量的估计 ($\hat{\mathbf{x}}_{k-1}, \hat{\mathbf{P}}_{k-1}$) 得到的

$$\hat{\mathbf{x}}_k^* = \mathbf{A} \hat{\mathbf{x}}_{k-1}$$

$$\hat{\mathbf{P}}_k^* = \mathbf{A} \hat{\mathbf{P}}_{k-1} \mathbf{A}^T + \mathbf{W}$$

上面有个星号是因为这个结果并不是最终在 k 时刻状态变量的估计值，是未经过修正的；

这个时候我们可以继续估计此时的观测信号 \mathbf{y}_k

$$\hat{\boldsymbol{\mu}}_k^* = \mathbf{H} \hat{\mathbf{x}}_k^*$$

$$\hat{\boldsymbol{\Sigma}}_k^* = \mathbf{H} \hat{\mathbf{P}}_{k-1}^* \mathbf{H}^T$$

然而，实际上我们的电极记录到的信号是 $(\mathbf{y}_k, \mathbf{Q})$ 与上面估计得到的 $\hat{\boldsymbol{\mu}}_k^*$ ， $\hat{\boldsymbol{\Sigma}}_k^*$ 并不一致，所以需要对我们一步估计的结果进行修正，这里先引入一个定理。

Combining Gaussians

高斯分布的组合，针对同一个变量，两个估计得到的高斯分布不同，可以通过将这两个高斯分布相乘得到新的高斯分布：

$$\mathcal{N}(x, \mu_0, \sigma_0) \cdot \mathcal{N}(x, \mu_1, \sigma_1) = \mathcal{N}(x, \mu_{new}, \sigma_{new})$$

其中

$$\mu_{new} = \mu_0 + \frac{\sigma_0^2 (\mu_1 - \mu_0)}{\sigma_0^2 + \sigma_1^2}$$

$$\sigma_{new}^2 = \sigma_0^2 - \frac{\sigma_0^4}{\sigma_0^2 + \sigma_1^2}$$

可以令 $g = \frac{\sigma_0^2}{\sigma_0^2 + \sigma_1^2}$, g 就是卡尔曼增益

$$\mu_{new} = \mu_0 + g(\mu_1 - \mu_0)$$

$$\sigma_{new}^2 = \sigma_0^2 - g \sigma_0^2$$

有了上面的公式之后，我们对于 \mathbf{y}_k 现在有一个估计和一个观测，并且都是高斯分布的，现在对于这两个高斯分布进行结合：

$$(\boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0) = (\mathbf{H}\hat{\mathbf{x}}_k^*, \mathbf{H}\hat{\mathbf{P}}_k^* \mathbf{H}^T)$$

$$(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1) = (\mathbf{y}_k, \mathbf{Q})$$

然后利用前面的公式进行组合得新的 $(\boldsymbol{\mu}_{new}, \boldsymbol{\Sigma}_{new})$

$$\boldsymbol{\mu}_{new} = \mathbf{H}\hat{\mathbf{x}}_k^* + \mathbf{G}(\mathbf{y}_k - \mathbf{H}\hat{\mathbf{x}}_k^*)$$

$$\boldsymbol{\Sigma}_{new} = \mathbf{H}\hat{\mathbf{P}}_k^* \mathbf{H}^T - \mathbf{G}(\mathbf{H}\hat{\mathbf{P}}_k^* \mathbf{H}^T)$$

这里的 $(\boldsymbol{\mu}_{new}, \boldsymbol{\Sigma}_{new})$ 就包含了当前时刻状态的及其方差的估计 $\hat{\mathbf{x}}_k$ ，即：

$$\mathbf{H}\hat{\mathbf{x}}_k = \mathbf{H}\hat{\mathbf{x}}_k^* + \mathbf{G}(\mathbf{y}_k - \mathbf{H}\hat{\mathbf{x}}_k^*)$$

$$\mathbf{H}\hat{\mathbf{P}}_k \mathbf{H}^T = \mathbf{H}\hat{\mathbf{P}}_k^* \mathbf{H}^T - \mathbf{G}(\mathbf{H}\hat{\mathbf{P}}_k^* \mathbf{H}^T)$$

$$\mathbf{G}_{new} = \mathbf{H}\hat{\mathbf{P}}_k^* \mathbf{H}^T (\mathbf{H}\hat{\mathbf{P}}_k^* \mathbf{H}^T + \mathbf{Q})^{-1}$$

两边去掉 \mathbf{H}, \mathbf{H}^T ，可以得到：

$$\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^* + \mathbf{G}_k(\mathbf{y}_k - \mathbf{H}\hat{\mathbf{x}}_k^*)$$

$$\hat{\mathbf{P}}_k = \hat{\mathbf{P}}_k^* - \mathbf{G}_k \mathbf{H} \hat{\mathbf{P}}_k^*$$

$$\mathbf{G}_k = \hat{\mathbf{P}}_k^* \mathbf{H}^T (\mathbf{H}\hat{\mathbf{P}}_k^* \mathbf{H}^T + \mathbf{Q})^{-1}$$

由此得到了 k 时刻状态变量的估计，然后不断重读这个过程直到时刻 K

一个形象的示意图就是，图中表示的是 $k - 1$ 时刻已知状态变量的估计值，利用已有信息和新观测到的变量 \mathbf{y}_k 对 k 时刻的状态变量进行估计；

